DATA-IA-EXE710 · Télécom Paris · Projet de groupe

Vélib' Métropole : peut-on prévoir une station vide dans 30 minutes ?

Une évaluation temporelle fondée sur les relevés réels du 25 au 30 octobre 2026

Réponse courte. La cible « station en service et sans vélo exactement à +30 minutes » est mesurable lorsque les deux relevés existent. Sur le test chronologique, la forêt aléatoire atteint un F1 de **0,570**, contre **0,562** pour la simple persistance de l'état actuel. Ce gain de 0,008, sur une seule coupure, ne permet pas d'affirmer que le modèle améliore durablement la prévision. Parmi les stations encore pourvues de vélos, le rappel n'est que de **10,4 %** pour la forêt.

Auteurs

Akram GHAZLOUNY · Youssef EJJIYAR · El Mehdi BEN YAHYA · Ahmed HUSSEIN

Dépôt GitHub (main) : ouvrir le dépôt principal

Notebook unique : ouvrir la version de remise dans Google Colab
Date de remise : 8 novembre 2026.

1 Question, périmètre et critères de réponse

La question du projet est : *une station Vélib' en service à l'instant t sera-t-elle vide exactement 30 minutes plus tard ?* Nous définissons « vide » par zéro vélo disponible et `is_renting=1`. Une station où l'emprunt est interdit n'est pas assimilée à une station vide : la situation est différente pour l'usager et pour l'analyse. Les données sont des instantanés de stations, pas des trajets individuels.

Le notebook principal retient uniquement les couples station–instant pour lesquels un relevé existe à t et à $t + 30$ minutes et pour lesquels l'emprunt est autorisé aux deux instants. La cible vaut 1 lorsque le nombre de vélos à $t + 30$ est nul. Cette sélection garantit une étiquette observée, mais elle restreint la réponse : une station ouverte à t puis fermée à $t+30$ est exclue *a posteriori*. La prédiction opérationnelle de toute indisponibilité, y compris une fermeture future, n'est donc pas étudiée ici.

Critère de réussite scientifique. Dépasser clairement une règle de référence sur un test chronologique distinct, surtout pour les stations qui ont encore des vélos au moment de la prédiction. Un score élevé sur toutes les stations peut simplement reconnaître celles qui sont déjà vides.

2 Données, qualité et gouvernance

Le collecteur conserve les flux publics GBFS `station_status.json` et `station_information.json` de Vélib' Métropole sous forme de JSON compressé, avec l'heure UTC de collecte et l'URL source. Le référentiel utilisé pour la jointure est figé au 25 octobre 2026. Le catalogue Paris Data décrit les données de disponibilité comme dynamiques et indique Smovengo/Syndicat Autolib' Vélib' Métropole comme producteur ; sa fiche affiche la licence ODbL pour *ce jeu de données catalogué*.[1] Les conditions applicables directement au flux GBFS doivent être vérifiées avant une redistribution autonome. L'attribution de la source et la date de consultation sont conservées dans la note de gouvernance et le dictionnaire des variables.

Contrôle sur la période retenue	Valeur
Créneaux de cinq minutes observés / attendus	1 736 / 1 740 (99,8 %)
Interruptions entre relevés	4 trous de 10 min
Lignes station × relevé avant exclusions	2 637 708
Stations avec signalement de plus de 24 h exclues	17
Stations analysées après exclusion	1 503
Observations de stations en service sans vélo	4,8 %

Le 25 octobre comporte 25 heures en raison du passage à l'heure d'hiver : 300 créneaux théoriques ce jour-là. Les doublons station–créneau sont résolus en conservant la collecte la plus récente ; les observations futures manquantes ne sont pas interpolées. L'audit glissant des 48 heures précédant le dernier relevé du 7 novembre trouvait seulement 9 instantanés sur 576 attendus (1,56 %). Ces données récentes, trop discontinues, ne sont pas mélangées aux six jours denses.

La gouvernance du projet distingue les données brutes, le référentiel, les contrôles qualité et la vue calculée dans le notebook. Aucun identifiant d'usager ni trajet individuel n'est enregistré. Les fichiers bruts restent versionnés et les règles de nettoyage sont documentées ; une conservation plus longue nécessite un stockage et une durée d'archivage explicitement définis.

3 Fermetures temporaires : contexte et biais

La Ville de Paris a annoncé 110 stations Vélib' fermées pour les manifestations du 24 octobre, avec réouverture progressive dans la nuit du 25 au 26.[2] Vélib' Métropole a annoncé 110 fermetures pour celles du 31 octobre, effectives dès le vendredi 30.[3] Il s'agit de fermetures de précaution liées aux manifestations ; les données du projet ne permettent pas de qualifier chaque fermeture de « grève » ni d'en attribuer la cause individuelle.

Dans les relevés du projet, les stations avec `is_renting != 1` sont environ 166 le dimanche 25, environ 20 en milieu de semaine et jusqu'à 142 en fin de journée le 30. La concordance temporelle avec les annonces est forte, mais le compteur GBFS agrège aussi d'autres raisons possibles de fermeture. Les taux de stations vides du notebook portent seulement sur celles où l'emprunt est possible. Le dimanche observé et la fin du test ne représentent pas nécessairement des conditions habituelles.



Figure 1 – Stations où la location est impossible dans les instantanés conservés. La courbe ne fournit pas la cause de l'indisponibilité. Source : calculs du notebook sur les flux GBFS archivés.

4 Géographie descriptive

Le notebook cartographie 1 498 stations ayant des observations en service et des coordonnées valides. La carte interactive `docs/carte-stations.html` permet d'afficher séparément les stations vides pendant au moins 20 % de leurs observations et les autres ; les fenêtres indiquent le nombre moyen de vélos. Dans les quatre quadrants définis par les médianes de latitude et longitude, le Nord-Est a une part moyenne de temps vide de 8,0 % contre 2,9 % pour le Sud-Est. Ces secteurs ne sont pas des divisions administratives, et six jours perturbés ne démontrent pas un effet causal de la localisation.

5 Méthode de prévision et évaluation

Les variables explicatives décrivent l'état présent (vélos, bornes libres, types, taux de remplissage), les variations à 15 et 30 minutes passées, une moyenne mobile sur les 30 minutes précédentes, l'heure, le jour, la période du jour, les coordonnées et la fréquence historique de vide de chaque station. Cette dernière est calculée sur l'entraînement seul. Une fenêtre mobile de moins de quatre relevés est signalée et remplacée par le compteur actuel ; une variation passée absente est imputée à zéro, ce qui peut masquer une variation inconnue. Aucune variable mesurée après t n'entre dans les modèles.

L'ensemble est découpé dans l'ordre du temps : entraînement jusqu'au 28 octobre à 13 h 05, validation du 28 octobre à 13 h 40 au 29 octobre à 10 h 45, test du 29 octobre à 11 h 20 au 30 octobre à 23 h 25. Un écart de 30 minutes avant chaque coupure empêche les étiquettes d'une période de déborder sur la suivante. Le test comporte 640 191 couples station–instant ; les seuils des classifieurs sont

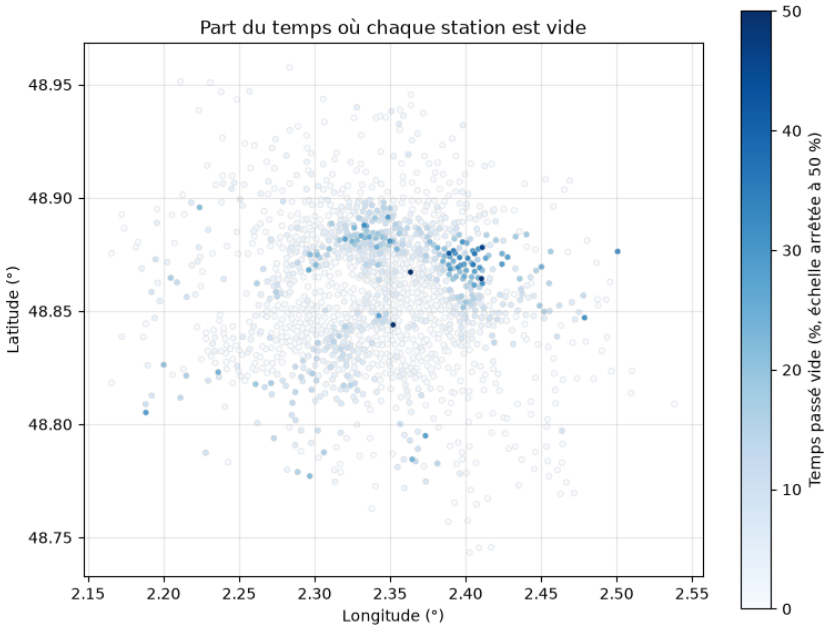


Figure 2 – Part du temps vide par station en service, du 25 au 30 octobre. Les points sont issus des relevés archivés ; la couleur représente une fréquence descriptive.

choisis sur la validation uniquement. L'entraînement des deux modèles utilise un échantillon reproductible de 300 000 lignes. Le comparateur « persistance » prédit qu'une station vide maintenant sera encore vide à +30 minutes.

Résultats sur toutes les stations du test

Modèle	Précision	Rappel	F1	PR-AUC
Persistance	0,560	0,565	0,562	–
Régression logistique	0,502	0,615	0,553	0,527
Forêt aléatoire	0,550	0,590	0,570	0,585

La forêt aléatoire produit 16 354 vrais positifs, 13 364 faux positifs et 11 353 faux négatifs, pour 599 120 vrais négatifs. Elle manque donc plus de 11 000 événements « vide » dans ce seul test, malgré un F1 global voisin de la persistance. La PR-AUC mesure le classement des risques ; elle ne transforme pas à elle seule ces prédictions en alertes utiles à un seuil choisi.

Ces valeurs détaillées proviennent d'une exécution avec NumPy 2.5.4, pandas 3.1.1 et scikit-learn 1.9.1. Une exécution intégrale dans Google Colab le 8 novembre a retrouvé le F1 de la forêt à 0,57 et l'erreur de régression à 1,45 vélo ; sa précision et son rappel de la forêt, arrondis à deux décimales, sont respectivement 0,57 et 0,56. Les versions autorisées par `requirements.txt` ne garantissent donc pas les mêmes valeurs au millième dans tous les environnements. La conclusion ne change pas.

Sous-ensemble initialement non vide : passage à vide à +30 min

Modèle	Précision	Rappel	F1	PR-AUC
Persistance	0,000	0,000	0,000	–
Régression logistique	0,247	0,136	0,176	0,184
Forêt aléatoire	0,354	0,104	0,160	0,225

Cette seconde table répond mieux au besoin d'anticipation : la forêt prédit correctement environ un tiers de ses alertes, mais ne repère qu'environ un passage à vide sur dix. La régression logistique

en repère davantage, avec une précision plus faible. Les résultats sont issus d'une seule coupure temporelle et de six journées d'automne ; ils ne mesurent pas la stabilité entre semaines ou en période sans manifestations.

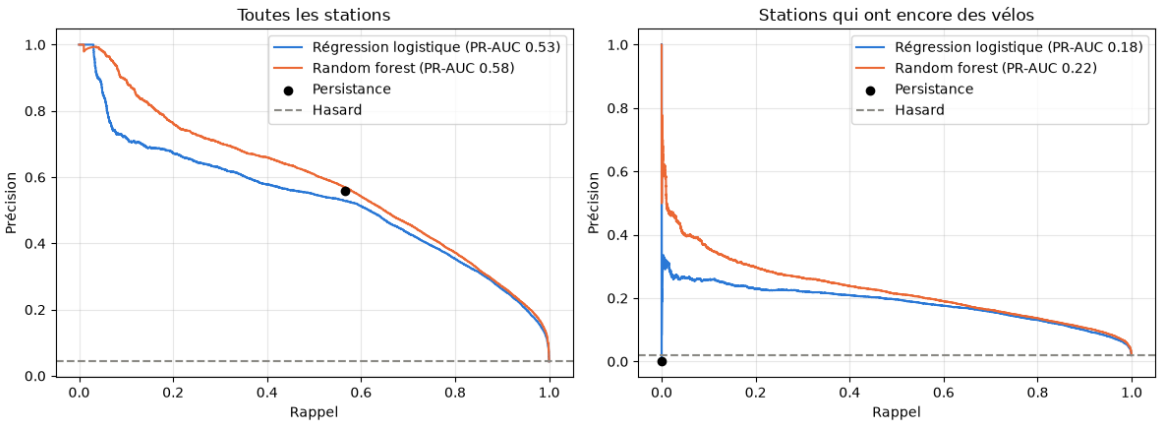


Figure 3 – Courbes précision–rappel du notebook principal : toutes les stations à gauche, stations initialement non vides à droite. Les seuils présentés dans les tables ont été fixés sur la validation.

6 Réponse et portée des résultats

Conclusion. Oui, le projet sait *construire* une cible exacte à +30 minutes et évaluer des modèles sur des relevés réels. Non, il ne démontre pas aujourd'hui une prévision fiable des stations qui vont se vider : le gain global de la forêt sur la persistance est négligeable et le rappel des nouveaux passages à vide est faible. Les stations fermées dans les 30 minutes suivantes sont hors du champ de l'évaluation.

Une régression complémentaire du nombre de vélos, dans le même notebook, obtient une erreur absolue moyenne de 1,45 vélo, contre 1,34 pour la règle « nombre de vélos inchangé ». Elle n'apporte donc pas de gain établi. Une seule cible de classification et un seul notebook d'analyse font autorité pour cette remise.

6.1 Apports scientifiques et interprétation des résultats

Un historique exploitable à partir de données temps réel. Le premier apport du projet est la constitution et la qualification d'un historique de disponibilités Vélib' à partir d'un flux ne fournissant que l'état courant des stations. Sur les six journées retenues, 1 736 des 1 740 créneaux attendus ont été observés, soit 99,8 % de couverture. Cette base permet d'étudier les dynamiques temporelles de 1 503 stations après les exclusions de qualité.

L'importance de comparer les modèles à une référence simple. La forêt aléatoire atteint un F1 de 0,570 contre 0,562 pour la persistance. L'écart de 0,008 est trop faible, sur cette seule séparation chronologique, pour établir une amélioration robuste. Ce résultat illustre l'importance d'une baseline : un modèle plus complexe n'est pas nécessairement plus utile qu'une règle simple.

La difficulté spécifique de l'anticipation. Seulement 4,8 % des observations de stations en service correspondent à une station vide. Sur le sous-ensemble des stations initialement non vides, la forêt aléatoire obtient une précision de 35,4 % et un rappel de 10,4 %. Elle identifie donc une partie des futurs passages à vide, mais en manque près de neuf sur dix. Le score global ne doit pas masquer cette difficulté centrale pour l'utilisateur.

Les enseignements méthodologiques. L'étude distingue la qualité des données, la capacité à construire une cible future vérifiable et la performance prédictive. Elle montre aussi l'intérêt d'une

évaluation chronologique, de l'analyse des faux négatifs et de la prise en compte des fermetures temporaires. La cible actuelle étant conditionnée au maintien en service de la station à l'instant futur, les résultats ne décrivent pas l'ensemble des situations d'indisponibilité.

Ces résultats constituent une base empirique pour poursuivre la recherche. Une évaluation sur plusieurs semaines, avec plusieurs périodes de test et une définition plus opérationnelle de l'indisponibilité, serait nécessaire avant de conclure à l'utilité d'un système de prévision.

6.2 Limites qui orientent la suite

— **Période et incidents.** Six jours, un seul dimanche et deux épisodes de fermeture encadrant la période ne suffisent pas à conclure sur un usage ordinaire, une saison ou l'effet des manifestations.

— **Sélection future.** L'exclusion des stations fermées à $t + 30$ utilise l'avenir pour définir la population évaluée. Elle est licite pour une analyse conditionnelle, mais ne peut être appliquée telle quelle à une alerte en temps réel.

— **Mesure.** Le flux photographie des disponibilités, sans identifier les trajets ni la cause des fermetures. `last_reported` n'est pas à lui seul une mesure de fraîcheur des compteurs.

— **Généralisation.** Une seule coupure de test, un seul tirage de 300 000 exemples d'entraînement et une collecte devenue intermittente après le 31 octobre ne permettent pas d'estimer la variabilité des performances.

6.3 Priorités après la remise

1. Rétablir une collecte vérifiée sur plusieurs semaines, avec alerte sur les trous et stockage adapté ; documenter les incidents de service connus.
2. Évaluer séparément les états « ouverte et vide », « ouverte et non vide » et « fermée », sans filtrer sur l'état futur pour un usage opérationnel.
3. Tester plusieurs semaines et plusieurs coupures temporelles, avec une analyse des jours perturbés, de la calibration et des faux négatifs.

7 Reproduction et livrables

Le dépôt public contient les instantanés, les contrôles qualité, le collecteur, les tests, le notebook unique exécuté, la carte HTML et la source de ce rapport. Pour reproduire les résultats, cloner le dépôt, utiliser la branche `main`, installer les dépendances de `requirements.txt`, lancer les tests unitaires, puis exécuter le notebook dans l'ordre. Depuis la racine du dépôt, compiler la source LaTeX avec Tectonic et les trois figures extraites du notebook. Les commandes exactes figurent dans le README ; les règles de provenance, nettoyage et conservation dans la note de gouvernance.

Le 8 novembre, les 53 cellules de code ont été exécutées jusqu'au bout dans un environnement Google Colab neuf, sans erreur. Une seconde exécution intégrale dans un environnement Python 3.12 propre et les sept tests unitaires ont également réussi. La revue par les quatre membres et la transmission par mail restent à faire par le groupe.

Sources

[1] Paris Data, « Vélib – Vélos et bornes – Disponibilité temps réel », consulté le 7 novembre 2026.

[2] Ville de Paris, fil d'information du 23 octobre 2026 : fermetures de stations Vélib' pour les manifestations du 24 octobre, consulté le 7 novembre 2026.

[3] Vélib' Métropole, « Fermeture temporaire de stations Vélib' à l'occasion des manifestations », annonce relative au 31 octobre 2026, consultée le 7 novembre 2026.

[4] Dépôt du groupe, `G-Akram01/velib-kit-data-science`, branche `main` ; notebook et données archivées consultés le 7 novembre 2026.