Vélib’ Métropole
Kit Data Science

Une station en service sera-t-elle vide exactement 30 minutes plus tard ?

Équipe : Akram GHAZLOUNY · Youssef EJJIYAR · El Mehdi BEN YAHYA · Ahmed HUSSEIN

25-30 oct.	99,8 %	1 503	4,8 %
Période étudiée	Créneaux observés	Stations analysées	Stations vides

Résumé

Nous avons constitué un historique d’instantanés du flux public GBFS Vélib’. La période du 25 au 30 octobre 2026 a une collecte presque complète : 1 736 créneaux observés sur 1 740 attendus, avec quatre trous de dix minutes. Les jours suivants sont trop espacés pour être intégrés à cette analyse temporelle.

Sur le test chronologique, une forêt aléatoire obtient un F1 de 0,563 contre 0,562 pour la règle de persistance. Cet écart de 0,001 ne démontre pas un avantage robuste. Les stations qui disposent encore de vélos sont les plus difficiles à anticiper.

Données et protocole

• Flux **station_status.json** : vélos, bornes libres, état de service et horodatages ; référentiel **station_information.json** du 25 octobre pour les noms, positions et capacités.

• Une ligne représente une station à un créneau de cinq minutes. Le 25 octobre compte 300 créneaux à cause du passage à l’heure d’hiver ; les autres jours en comptent 288 en théorie.

• La cible vaut 1 quand la station est en service aux deux instants et n’a plus de vélo exactement à +30 minutes. Les créneaux sans observation future correspondante sont exclus, sans interpolation.

• Les variables du modèle décrivent l’état présent, l’heure, la localisation, l’historique de la station calculé sur l’entraînement et les variations des 15 et 30 minutes précédentes.

Le code, les données et le notebook exécutable sont disponibles dans le dépôt GitHub du projet.

1. Couverture et qualité des données

Indicateur	Résultat sur la période retenue
Créneaux observés / attendus	1 736 / 1 740 (99,8 %)
Interruptions	4 trous de 10 min ; aucun > 15 min
Observations avant exclusion des stations anciennes	2 637 708 lignes station × créneau
Stations exclues pour signalement ancien	17 au dernier relevé de la période
Détail mécanique / électrique absent	18 relevés sur 1 736
Vélos + bornes libres < capacité de référence	50,4 % des observations

Le champ **last_reported** présente un rythme proche de l'heure, alors que certains compteurs varient entre deux collectes. Son âge ne prouve pas directement que le nombre de vélos est périmé. L'écart à la capacité peut notamment correspondre à des bornes indisponibles ; la cause de chaque écart n'est pas observable dans ces flux.

2. Disponibilité observée

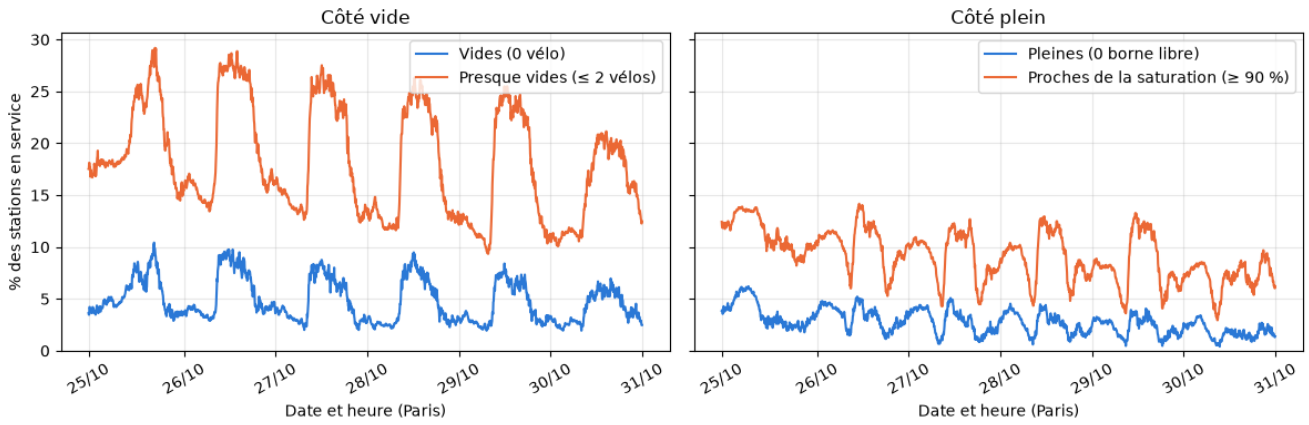


Figure 1. Part des stations en service vides, presque vides, pleines et proches de la saturation, du 25 au 30 octobre. Les courbes montrent des variations quotidiennes, sans démontrer une cause.

En moyenne, **4,8 %** des stations en service sont vides et **18,3 %** ont au plus deux vélos. Les stations de vingt bornes ou moins sont vides dans 8,2 % de leurs observations, contre 2,4 % pour les stations de plus de quarante bornes. Cette comparaison est descriptive.

3. Répartition géographique

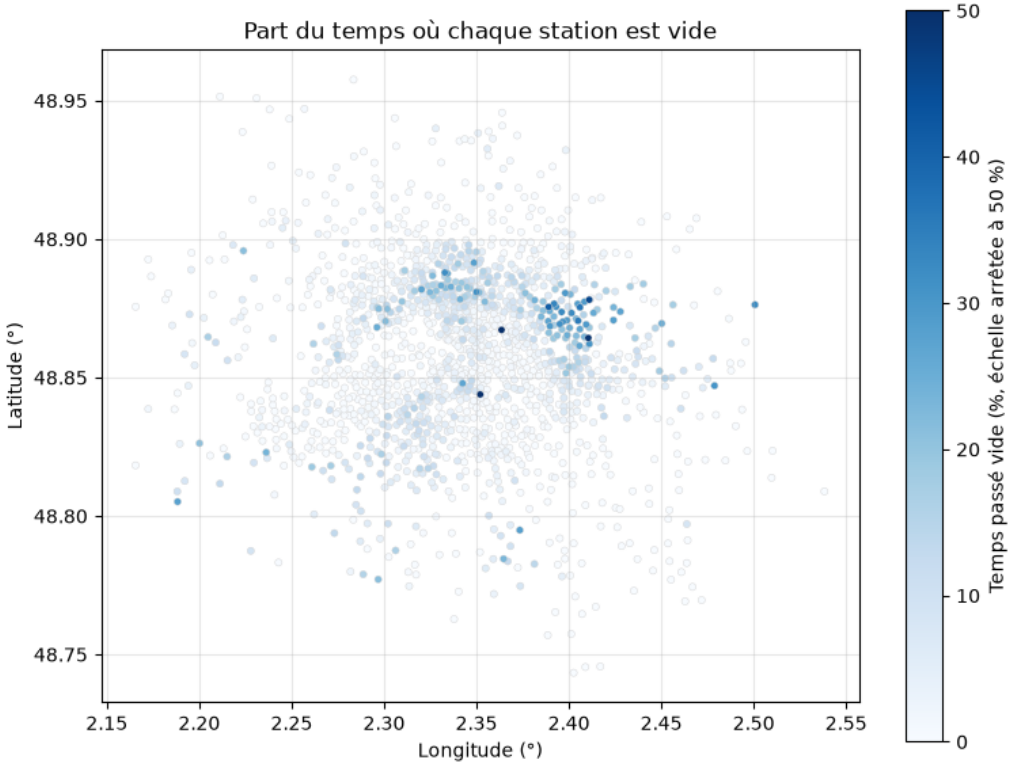


Figure 2. Part du temps où chaque station est vide ; l'échelle de couleur est plafonnée à 50 %. La carte suggère des regroupements mais aucun test spatial n'est effectué.

Sur la période, 32 % des stations analysées ne sont jamais vides et les 10 % les plus souvent vides concentrent 47 % des observations de station vide. Deux stations sont vides dans plus de 95 % de leurs observations en service.

4. Évaluation chronologique

Les périodes d'entraînement, de validation et de test se suivent dans le temps, avec une marge de 30 minutes aux frontières. Le seuil de décision est choisi sur la validation. Le test couvre du 29 octobre à 11 h 20 au 30 octobre à 23 h 25 (heure de Paris) et contient 640 191 exemples.

Méthode	Précision	Rappel	F1	PR-AUC
Persistance	0,560	0,565	0,562	-
Régression logistique	0,499	0,616	0,551	0,526
Forêt aléatoire	0,549	0,578	0,563	0,581

5. Interprétation des prédictions

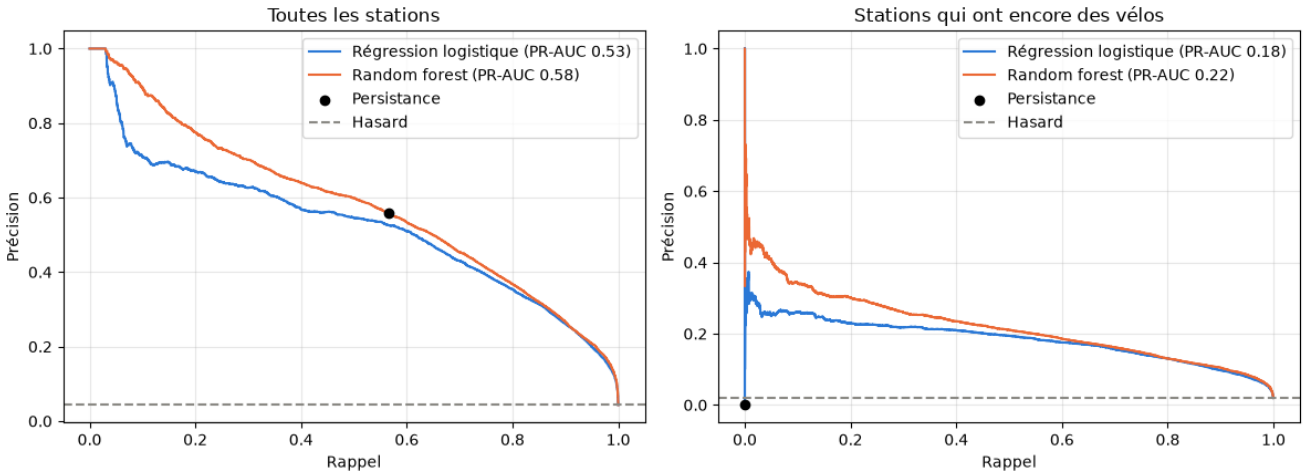


Figure 3. Courbes précision-rappel sur le test. À gauche : toutes les stations ; à droite : stations qui ont encore des vélos à l'instant de prédiction. La ligne grise correspond à la fréquence de la classe positive.

La forêt aléatoire dépasse la persistance de **0,001 point de F1** sur toutes les stations : l'écart est trop faible pour conclure à un gain. Sur les stations encore pourvues de vélos, elle obtient une précision de 0,340 et un rappel de 0,104 ; la régression logistique atteint un rappel de 0,143. Une régression complémentaire du nombre de vélos à +30 minutes a une erreur moyenne de 1,47 vélo contre 1,34 pour la règle « nombre inchangé ».

Limites

• Une seule semaine d'automne et une seule découpe chronologique : les scores ne mesurent ni la stabilité entre semaines ni les effets saisonniers.

• Le statut « vide » additionne vélos mécaniques et électriques ; il ne décrit pas la disponibilité d'un type précis.

• Le flux donne des instantanés, sans trajets individuels ni cause des changements brusques. Les observations après le 31 octobre sont trop espacées pour cette évaluation.

Reproductibilité et sources

Installer les dépendances de **requirements.txt**, lancer **python -m unittest discover -s tests -v**, puis exécuter toutes les cellules de **notebooks/Analyse_velib_V_07_11.ipynb** dans l'ordre. Les sept tests unitaires passent dans l'environnement de vérification. Le notebook final a été réexécuté intégralement sur la copie du dépôt.

Source des données : documentation officielle GBFS Vélib' Métropole. Période de collecte : 25-30 octobre 2026. Analyse et rapport préparés le 7 novembre 2026.